

Actividad 3

Luis Daniel Dimas Ramirez

16/12/2022

1

- a. Basandome en las distribuciones de probabilidad discutidas en clase, considero que la distribución **Gamma** es la que mejor se ajusta al comportamiento de mi variable de Magnitud. En el caso de las estaciones considero que la distribución **Poisson** puede ajustarse a mis datos.

Para tener como referencia mis distribuciones, las pondre a continuación:

```
x <- read.csv("x1.csv")
est <- x$st

tabla_est <- table(est)
tablar_est <- prop.table(tabla_est)

range(na.omit(est))
```

```
## [1] 10 130
```

```
hist_est <- hist(est,breaks=seq(0,140,20),plot=F)
n <- length(hist_est$breaks)
tab_est <- cbind(hist_est$breaks[-n],hist_est$breaks[-1],
                hist_est$counts,
                hist_est$counts/sum(hist_est$counts),
                cumsum(hist_est$counts),
                cumsum(hist_est$counts/sum(hist_est$counts)))
dimnames(tab_est)[[2]]<-c("Linf","Lsup","f","fr","F","Fr")
print(tab_est)
```

```
##      Linf Lsup  f   fr   F   Fr
## [1,]    0   20 473 0.473 473 0.473
## [2,]   20   40 313 0.313 786 0.786
## [3,]   40   60 113 0.113 899 0.899
## [4,]   60   80  61 0.061 960 0.960
## [5,]   80  100  27 0.027 987 0.987
## [6,]  100  120  11 0.011 998 0.998
## [7,]  120  140   2 0.002 1000 1.000
```

```
mag <- x$mag
(tabla_mag <- table(mag))
```

```
## mag
## 4 4.1 4.2 4.3 4.4 4.5 4.6 4.7 4.8 4.9 5 5.1 5.2 5.3 5.4 5.5 5.6 5.7 5.9 6
## 46 55 90 85 101 107 101 98 65 54 47 43 29 21 20 14 9 8 2 3
## 6.1 6.4
## 1 1
```

```
(tablar_mag <- prop.table(tabla_mag))
```

```
## mag
## 4 4.1 4.2 4.3 4.4 4.5 4.6 4.7 4.8 4.9 5 5.1 5.2
## 0.046 0.055 0.090 0.085 0.101 0.107 0.101 0.098 0.065 0.054 0.047 0.043 0.029
## 5.3 5.4 5.5 5.6 5.7 5.9 6 6.1 6.4
## 0.021 0.020 0.014 0.009 0.008 0.002 0.003 0.001 0.001
```

```
range(na.omit(mag))
```

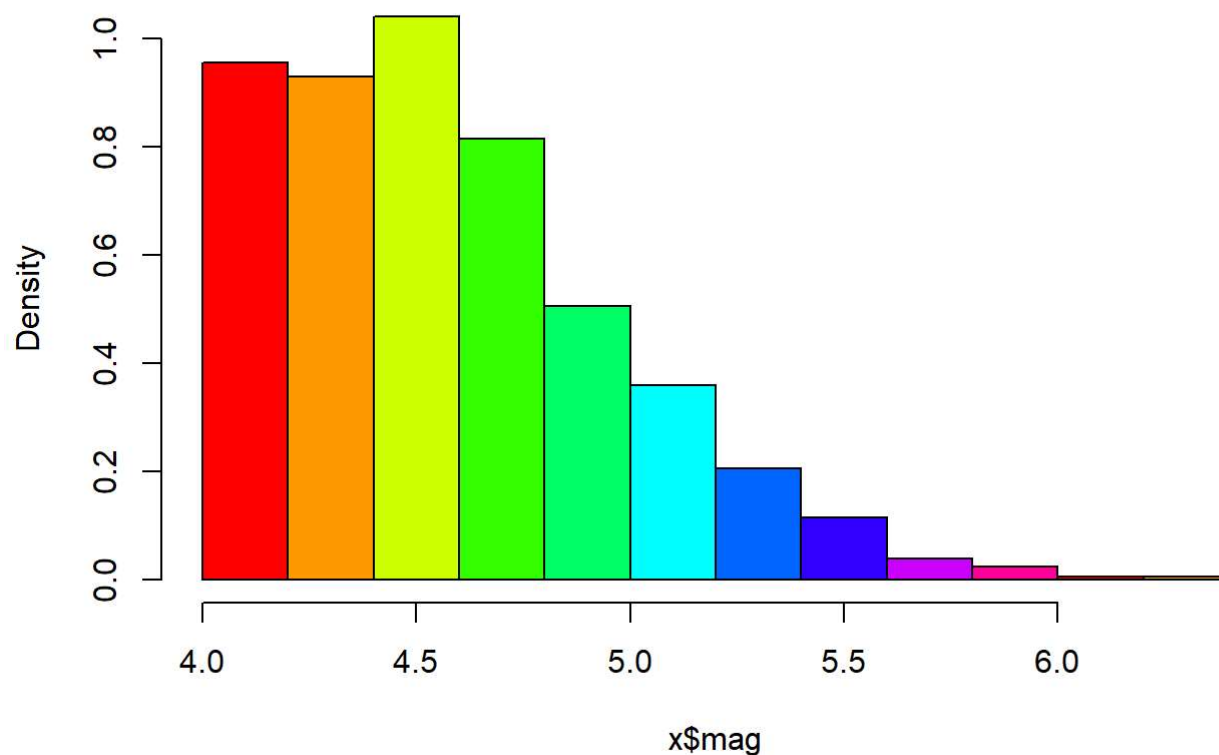
```
## [1] 4.0 6.4
```

```
hist_mag <- hist(mag,breaks=seq(4,6.5,0.5),plot=F)
n <- length(hist_mag$breaks)
tab_mag <- cbind(hist_mag$breaks[-n],hist_mag$breaks[-1],
                hist_mag$counts,
                hist_mag$counts/sum(hist_mag$counts),
                cumsum(hist_mag$counts),
                cumsum(hist_mag$counts/sum(hist_mag$counts)))
dimnames(tab_mag)[[2]]<-c("Linf","Lsup","f","fr","F","Fr")
print(tab_mag)
```

```
## Linf Lsup f fr F Fr
## [1,] 4.0 4.5 484 0.484 484 0.484
## [2,] 4.5 5.0 365 0.365 849 0.849
## [3,] 5.0 5.5 127 0.127 976 0.976
## [4,] 5.5 6.0 22 0.022 998 0.998
## [5,] 6.0 6.5 2 0.002 1000 1.000
```

```
par(mfrow=c(1,1))
hist(x$mag, col=rainbow(10), main="Histograma de la magnitud de \n sismos en Fiji", prob=T)
```

Histograma de la magnitud de sismos en Fiji



b.

Variables	Distribución propuesta
Magnitud	Gamma
Estaciones	Poisson

2 Estimación puntual de los parametros

Discreta - Estaciones

Escribe una funcion que calcule la funcion de verosimilitud para la distribucion Poisson

Para este caso, debido a que trabajare con la distribución de Poisson, sabemos lo siguiente:

$$f(x; \lambda) = \frac{e^{-\lambda} \lambda^x}{x!}$$

Realizando el proceso para calcular la funcion $L(\theta)$ obtengo que

$$\lambda = \frac{\sum x_i}{n} = E(x) = \bar{x}$$

Por lo tanto:

```
lambda<- function(x,n){
  sum(x)/n
}

lambda(x$st, length(x$st))
```

```
## [1] 32.84
```

Estimando el parametro con el optimizador obtengo lo siguiente

```
library(fitdistrplus)
```

```
## Loading required package: MASS
```

```
## Loading required package: survival
```

```
(fitp <- fitdistr(x$st, densfun = "Poisson"))
```

```
##      lambda
## 32.8400000
## ( 0.1812181)
```

Metodo	λ
$L(\theta)$	32.8
fitdistr()	32.84

```
f <- 1:130
barplot(tablar_est, pch=20 ,main="Diagrama de barras de las estaciones (rojo) \n VS Distribución
Poisson (gris)", ylim = c(0,0.7), col = "red")


g<- seq(10,130, by=10)
modelo_estaciones<- dpois(g,lambda= fitp$estimate)
rbind(tablar_est,modelo_estaciones)
```

```
##           10           20           30           40           50
## tablar_est 1.67000e-01 0.306000000 0.20600000 0.10700000 0.069000000
## modelo_estaciones 2.19805e-06 0.004783079 0.06400348 0.03035639 0.001188097
##           60           70           80           90
## tablar_est 4.400000e-02 4.100000e-02 2.00000e-02 2.000000e-02
## modelo_estaciones 6.335535e-06 6.420732e-09 1.56781e-12 1.101836e-16
##           100          110          120          130
## tablar_est 7.00000e-03 5.000000e-03 6.000000e-03 2.000000e-03
## modelo_estaciones 2.55906e-21 2.193804e-26 7.598943e-32 1.146794e-37
```

```
library(grDevices) # paquete basico
micolor<- adjustcolor( "gray", alpha.f = 0.5) # alpha.f ajusta lo transparente

barplot(modelo_estaciones*10,col=micolor,add=T) # encimamos la graficas
```

Diagrama de barras de las estaciones (rojo) VS Distribución Poisson (gris)



Despues de observar esta grafica, y tratar de ajustarla con diferentes lambdas, la que más se acerca es cuando lambda es igual a 20 pero aun asi creo que no se ajusta bien. Me parece que tratare con otra distribución esperando que se ajuste mejor.

```
barplot(tablar_est, pch=20 ,main="Diagrama de barras de las estaciones (rojo) \n VS Distribución Poisson (gris)", ylim = c(0,0.7), col = "red")


g<- seq(10,130, by=10)
modelo_estaciones<- dpois(g,lambda= 20)
rbind(tablar_est,modelo_estaciones)
```

```
##              10          20          30          40          50
## tablar_est      0.16700000 0.30600000 0.20600000 1.070000e-01 6.900000e-02
## modelo_estaciones 0.005816307 0.08883532 0.008343536 2.777571e-05 7.630189e-09
##              60          70          80          90
## tablar_est      4.400000e-02 4.100000e-02 2.000000e-02 2.000000e-02
## modelo_estaciones 2.855849e-13 2.031445e-18 3.481627e-24 1.717411e-30
##              100         110         120         130
## tablar_est      7.000000e-03 5.000000e-03 6.000000e-03 2.000000e-03
## modelo_estaciones 2.799666e-37 1.684582e-44 4.095585e-52 4.338271e-60
```

```
library(grDevices) # paquete basico
micolor<- adjustcolor( "gray", alpha.f = 0.5) # alpha.f ajusta lo transparente

barplot(modelo_estaciones*5,col=micolor,add=T) # encimamos la graficas
```

Diagrama de barras de las estaciones (rojo) VS Distribución Poisson (gris)



Mientras estaba probando mis datos simulados me di cuenta que son muy pequeños y que al multiplicarlos por 5 o por 10, se aproximan mejor

Probando con otras distribuciones discretas

```
(fitg <- fitdistr(x$st, densfun = "geometric"))
```

```
##          prob
## 0.0295508274
## (0.0009205684)
```

```
barplot(tablar_est, pch=20 ,main="Diagrama de barras de las estaciones (rojo) \n VS Distribución Geomtrica (gris)", ylim = c(0,0.7), col = "red")
```


```
modelo_estaciones<- dgeom(g,fitg$estimate)
rbind(tablar_est,modelo_estaciones)
```

```
##          10          20          30          40          50
## tablar_est    0.16700000 0.30600000 0.20600000 0.10700000 0.06900000
## modelo_estaciones 0.02189261 0.01621905 0.01201582 0.008901873 0.006594917
##          60          70          80          90          100
## tablar_est    0.044000000 0.041000000 0.020000000 0.020000000 0.007000000
## modelo_estaciones 0.004885818 0.003619639 0.002681595 0.001986649 0.001471801
##          110          120          130
## tablar_est    0.005000000 0.006000000 0.002000000
## modelo_estaciones 0.001090378 0.000807802 0.0005984569
```

```
library(grDevices) # paquete basico
micolor<- adjustcolor( "gray", alpha.f = 0.5) # alpha.f ajusta lo transparente

barplot(modelo_estaciones*10,col=micolor,add=T) # encimamos la grafica
```

Diagrama de barras de las estaciones (rojo) VS Distribución Geométrica (gris)



Considero levemente mejor ajustada la distribución geométrica que la poisson. Así que me quedare con esta teniendo en cuenta que es $p * 10$

El parametro para la geométrica es:

$$p = 0.2955083$$

Continúa

Considero que una distribución gamma puede aproximarse a mi variable de magnitud

```
(fit<- fitdistr(x$mag, densfun = "gamma"))
```

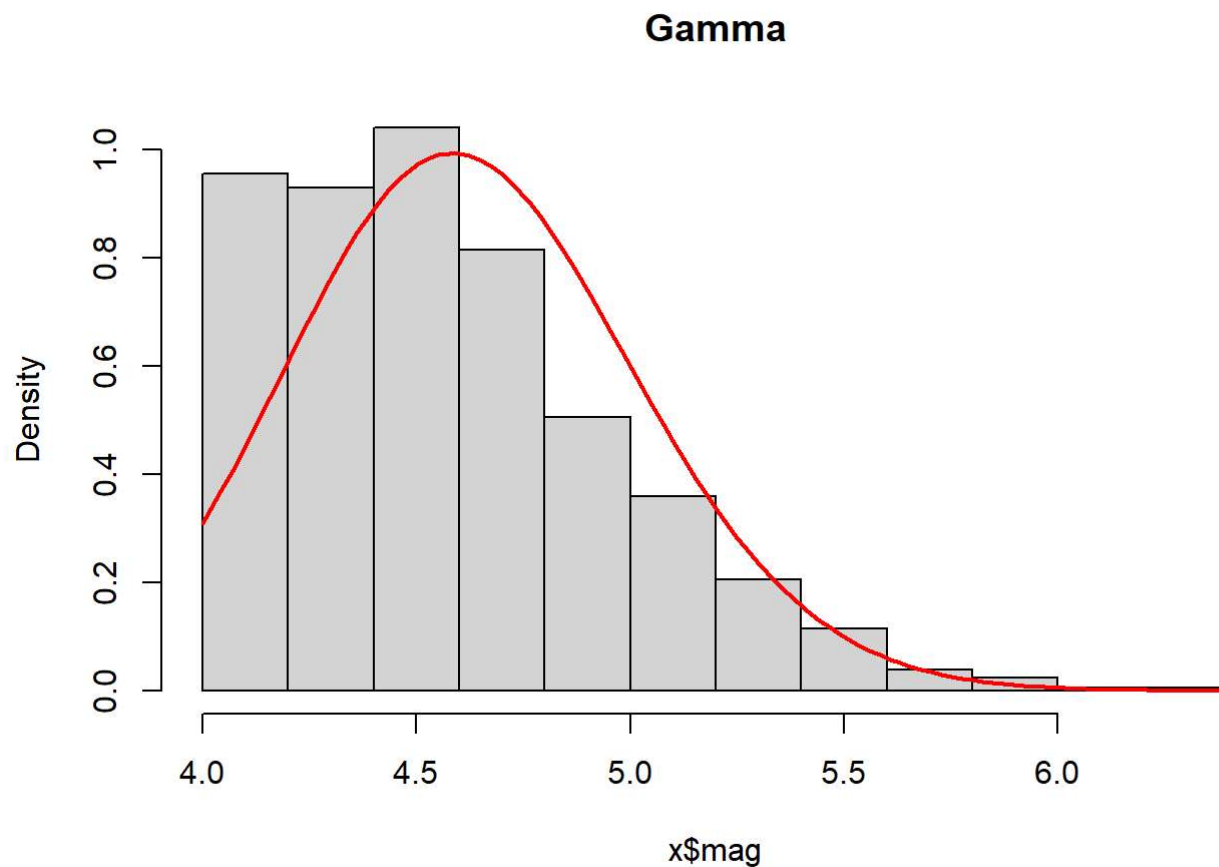
```
##      shape      rate
## 131.594743 28.481323
## ( 5.877149) ( 1.274423)
```

```
ee_MLE <- sqrt(fit$vcov); ee_MLE
```

```
##      shape      rate
## shape 5.877149 2.734182
## rate 2.734182 1.274423
```




```
hist(x$mag, pch=20, prob=TRUE, main="Gamma")  
curve(dgamma(x, fit$estimate[1], fit$estimate[2]), col="red", lwd=2, add=T)
```



Grafica Cullen-Frey

```
descdist(x$mag)
```

Cullen and Frey graph



```
## summary statistics
## -----
## min: 4    max: 6.4
## median: 4.6
## mean: 4.6204
## estimated sd: 0.402773
## estimated skewness: 0.7697548
## estimated kurtosis: 3.518884
```

De la grafica cullen-frey observo que la distribución gamma es una buena opcion pero tambien podria probar con la distribucion weibull e incluso la lognormal.


```
(fit<- fitdistr(x$mag, den = "lognormal"))
```

```
##      meanlog      sdlog
## 1.526810316 0.085035540
## (0.002689060) (0.001901452)
```

```
ee_MLE <- sqrt(fit$vcov); ee_MLE
```

```
##          meanlog      sdlog
## meanlog 0.00268906 0.000000000
## sdlog   0.00000000 0.001901452
```

```
hist(x$mag, pch=20, prob=TRUE, main="Log Normal")
curve(dlnorm(x, fit$estimate[1], fit$estimate[2]), col="red", lwd=2, add=T)
```



```
(fitw<- fitdistr(x$mag, den = "weibull"))
```

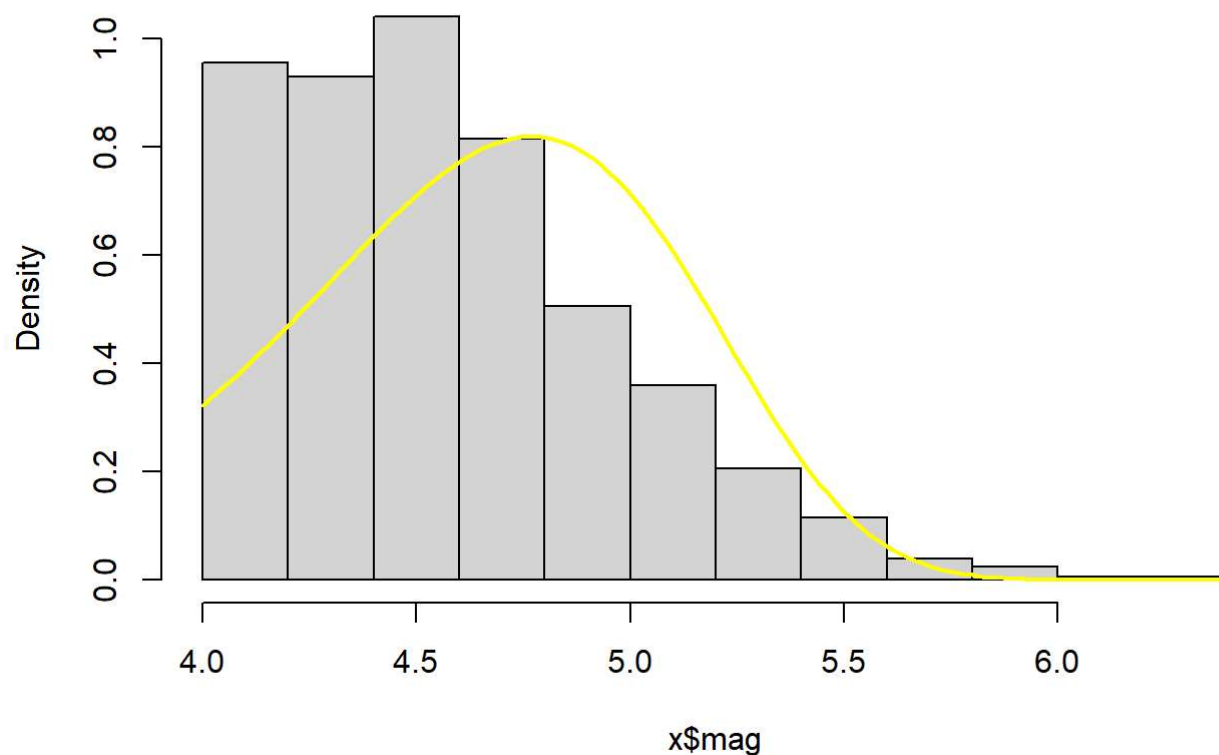
```
##      shape      scale
## 10.67255750  4.81257866
## ( 0.23156634) ( 0.01515957)
```

```
ee_MLEw <- sqrt(fit$vcov); ee_MLEw
```

```
##          meanlog      sdlog
## meanlog 0.00268906 0.000000000
## sdlog   0.00000000 0.001901452
```

```
hist(x$mag, pch=20, prob=TRUE, main="Weibull")
curve(dweibull(x, fitw$estimate[1], fitw$estimate[2]), col="yellow", lwd=2, add=T)
```

Weibull



Para el caso de la magnitud concluyo que la funcion LogNormal se acerca ligeramente más a mis datos que la Gamma.

```
(fitg<- fitdistr(x$mag, densfun = "gamma"))
```

```
##      shape      rate
## 131.594743 28.481323
## ( 5.877149) ( 1.274423)
```

```
ee_MLEg <- sqrt(fit$vcov); ee_MLEg
```

```
##      meanlog      sdlog
## meanlog 0.00268906 0.00000000
## sdlog   0.00000000 0.001901452
```

```
(fitl<- fitdistr(x$mag, den = "lognormal"))
```

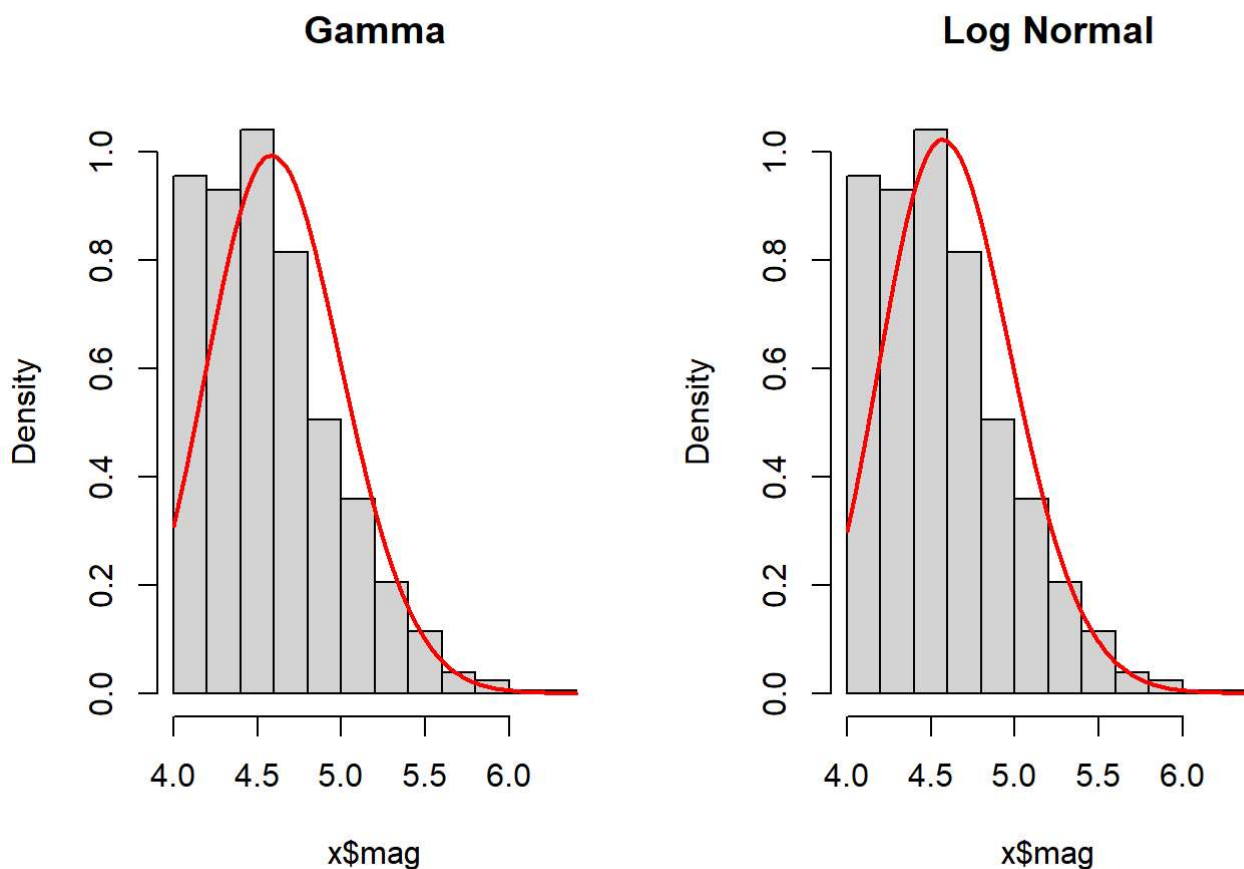
```
##      meanlog      sdlog
## 1.526810316 0.085035540
## (0.002689060) (0.001901452)
```

```
ee_MLE1 <- sqrt(fit$vcov); ee_MLE1
```

```
##          meanlog      sdlog
## meanlog 0.00268906 0.00000000
## sdlog    0.00000000 0.001901452
```

```
par(mfrow=c(1,2))
hist(x$mag, pch=20, prob=TRUE, main="Gamma")
curve(dgamma(x, fitg$estimate[1], fitg$estimate[2]), col="red", lwd=2, add=T)

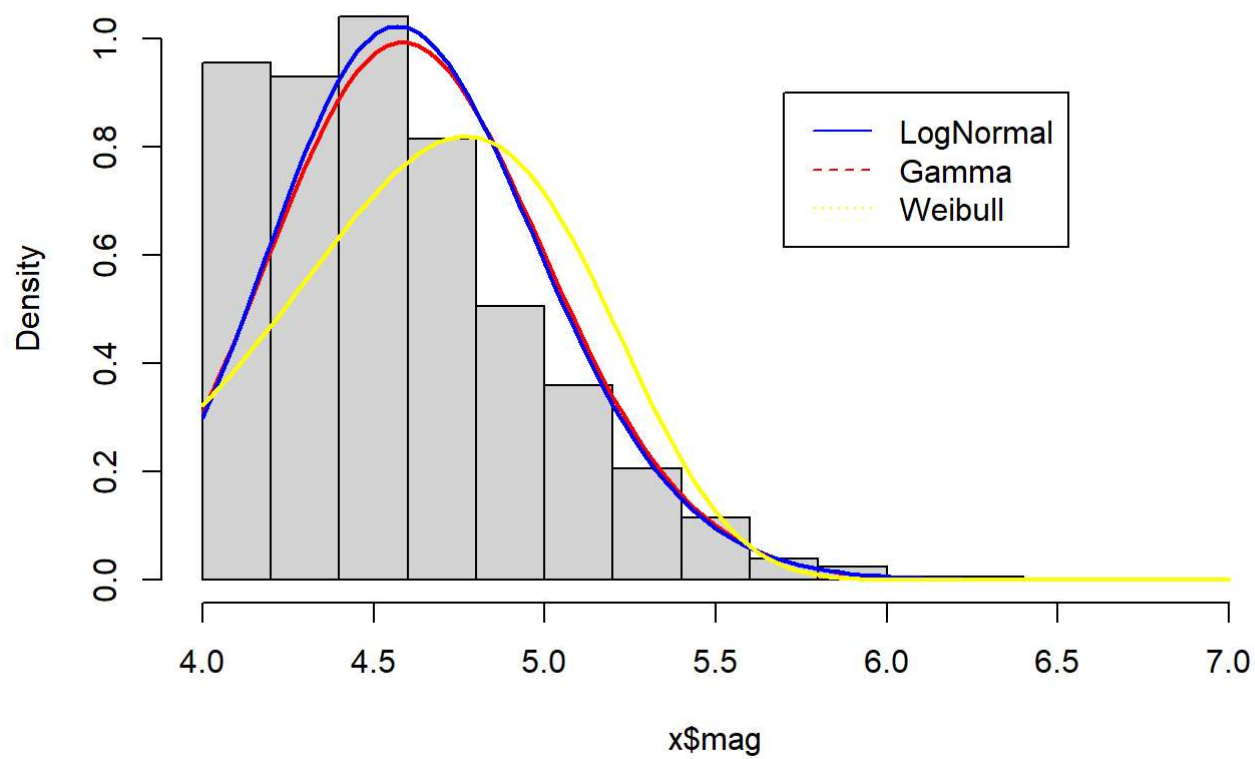
hist(x$mag, pch=20, prob=TRUE, main="Log Normal")
curve(dlnorm(x, fitl$estimate[1], fitl$estimate[2]), col="red", lwd=2, add=T)
```



Comparandolas en una sola gráfica:

```
hist(x$mag, pch=20, prob=TRUE, main="Histograma de magnitudes", xlim=c(4,7))
curve(dgamma(x, fitg$estimate[1], fitg$estimate[2]), col="red", lwd=2, add=T)
curve(dlnorm(x, fitl$estimate[1], fitl$estimate[2]), col="blue", lwd=2, add=T)
curve(dweibull(x, fitw$estimate[1], fitw$estimate[2]), col="yellow", lwd=2, add=T)
legend(x=5.7, y=0.9, legend = c("LogNormal", "Gamma", "Weibull"), col=c("blue", "red", "yellow"), lty = 1:3)
```

Histograma de magnitudes



La lognormal es la que mejor se ajusta a mis datos.